




GRAFO DE CONHECIMENTO

ANÁLISE CLÍNICA A PARTIR DE TEXTO — CASOS MULTICARE

Extração de entidades com dicionário UMLS

INTEGRANTES:

Andrés Rodas

Jared Orihuela

Emanuel Ricasca

Diego Monzón


Fernando Nagano Foschiera

UNICAMP-IC

Natural Language Processing

Projeto 1





AGENDA

/02

1

MOTIVAÇÃO

2

CORPUS LIMPEZA

3

VOCABULÁRIO CONTROLADO

4

PIPELINE

5

EXTRAÇÃO DE ENTIDADES

6

EXTRAÇÃO DE RELAÇÕES

7



VISUALIZADOR


8

VALIDAÇÃO

9

LIMITES E ENCERRAMENTO





MOTIVAÇÃO

/03

O CONHECIMENTO CLÍNICO FICA PRESO À PROSA


Cada relato de caso descreve diagnósticos, tratamentos e resultados de exames em texto livre. É legível para um médico, mas não é pesquisável, nem comparável entre pacientes, nem associável a vocabulários padronizados.


Objetivo do projeto

- Converter 50 narrativas de pacientes reais em anotações estruturadas e um grafo explorável.
- Ancorar cada entidade a um CUI da UMLS para garantir vocabulário clínico padronizado, não rótulos ad-hoc.
- Manter a rastreabilidade: cada nó aponta para o texto-fonte e o método de extração.

Três etapas

- Extrair - NER léxico por correspondência mais longa contra um gazetteer da UMLS.
- Vincular - cada medição (dose, tamanho, dia) à entidade clínica que descreve.
- Visualizar - um grafo interativo por paciente, não apenas uma tabela de anotações.





CORPUS E LIMPEZA

/04

56 LINHAS DE ORIGEM NÃO ERAM 56 PACIENTES

`clean_cases.py` audita o corpus antes que qualquer outra coisa seja executada.

56 → 50

linhas de cases.csv →
pacientes reais

56 → 50


linhas de cases.csv →
pacientes reais

O que foi descartado e por quê

1. Um resumo de coorte retrospectiva de 115 pacientes marcado como `case_amount=1`.
2. Um artigo de metodologia de ensino odontológico, sem paciente.
3. Um artigo de sociologia sobre a Theranos, sem paciente clínico.

Idade e sexo, re-derivados do texto

1. As colunas originais têm erros confirmados — um caso registra `age=39` para um recém-nascido de 39 semanas de gestação.
2. São re-extraídos com regex sobre a cláusula "A/An N-year-old..." e ambos os valores (`age/age_upstream`) são preservados para auditoria.



VOCABULÁRIO CONTROLADO

/05

UM GAZETTEER DA UMLS, NÃO UMA LISTA DE PALAVRAS-CHAVE

14 tipos semânticos (TUI), 6 vocabulários-fonte, filtrados a termos em inglês e não suprimidos.

1,66M

inhas consolidadas
(umls_clinico_todos.csv)

644,5K

CUIs únicos cobertos

1,10M


termos indexados em
gazetteer.db

Vocabulários-fonte


SNOMEDCT_US · MSH ·

LNC · RXNORM · ICD10CM

· MTH



```
PALETTE = {  
  "Diagnosis": (["#2a78d6", "#3987e5"], # slot 1 blue  
  "Treatment": (["#eb6834", "#d95926"], # slot 2 orange  
  "Exam": (["#1baf7a", "#199e70"], # slot 3 aqua  
  "Finding": (["#eda100", "#c98500"], # slot 4 yellow  
  "Symptom": (["#e87ba4", "#d55181"], # slot 5 magenta  
  "BodyPart": (["#008300", "#008300"], # slot 6 green  
  "Measurement": (["#64748b", "#94a3b8"], # slot 7 slate -- value/unit  
  "Person": (["#334155", "#334155"],  
  "Age": (["#8b5cf6", "#8b5cf6"],  
  "Sex": (["#0891b2", "#0891b2"],  
}
```








PIPELINE

/06

DUAS ENTRADAS, UM MESMO GRAFO

Tudo, incluindo o app, roda extração ao vivo sobre a mesma `extract()` — o pipeline e o visualizador nunca podem ficar dessincronizados.






EXTRAÇÃO DE ENTIDADES

/07

Em cada posição testa-se a janela de 6 tokens até 1, pulando para depois do que deu match — "acute pancreatitis" (C0001339) é um conceito distinto de "pancreatitis" (C0030305).


3.134 ENTIDADES · 50 PACIENTES

Treatment		744
Finding		687
Diagnosis		589
BodyPart		546
Exam		408
Symptom		160
Measurements		550



POR QUE "MAIS LONGA" IMPORTA

- Janela de 6 tokens — subir para 8 só encontra 1 entidade adicional em todo o corpus.
- Referências a figuras/tabelas são mascaradas antes de tokenizar — "Fig" também é um termo da UMLS (a fruta).
- Os medicamentos não são uma categoria à parte: RXNORM/MSH já os resolvem dentro de Treatment.



EXTRAÇÃO DE RELAÇÕES

/08

De "menciona" a "tratado com" — relações tipadas

um CRF linear-chain faz BIO-tagging de gatilhos de relação por oração e decodifica com Viterbi — sem dados rotulados, os pesos são fixados à mão.

849


relações documentadas · 50
pacientes · 8 tipos

828

reproduzidas nesta corrida
local (gazetteer reduzido ao
corpus)


39

testes novos em
test_relations.py — 100%
passam




Por status de asserção (828)

- REGRA DE COORDENAÇÃO INVERTIDA: VÍRGULA SEPARA 34% DOS PARES DE ENTIDADES ADJACENTES — VIROU SINAL (COORDINATE_WITH), NÃO DESCARTE.
- ESCOPO DE NEGAÇÃO AO ESTILO NEGEX/CONTEXT: UMA RELAÇÃO NEGADA É MARCADA, NUNCA DESCARTADA.



MODELO CONCEPTUAL




ORIGEM	RELACAO	DESTINO	SIGNIFICADO
Article	REPORTS_PERSON	Person	O artigo reporta este paciente
Person	HAS_AGE/HAS_SEX	Age / Sex	Valores re-derivados por clean_cases.py
Person	MENTIONS_*	Concept / mention	O termo clínico aparece no relato
Concept	ASSOCIATED_WITH_MEASUREMENT	Measurement	Associação heurística a uma ocorrência exata do texto
Person	CONTAINS_UNLINKED_MEASUREMENT	Measurement	Valor extraído sem associação resolvida

Visualizador en Draw.io

Image source:


https://viewer.diagrams.net/tags=%7B%7D&lightbox=1&highlight=0000ff&edit=_blank&layers=1&nav=1&title=Modelo%20conceptual.drawio&dark=auto#Uhttps%3A%2F%2Fdrive.google.com%2Fuc%3Fid%3D12lbvMW2ebPxxkQeZGTfBm_5AYcjzblmnO%26export%3Ddownload



VISUALIZADOR

streamlit run src/app.py — três abas sobre a mesma extração ao vivo.

/10



Texto anotado

Realça cada entidade inline (~35 ms por caso);
ao passar o cursor mostra CUI, tipo semântico
e vocabulário-fonte.

Grafo de conhecimento

Cytoscape.js 3.33.1 embutido localmente
(sem CDN, sem Node, sem Neo4j). Busca por
nome/CUI, filtros por tipo e método de
vínculo, agrupar por categoria IS_A, layouts
force/hierárquico/circular

Tabelas e exportação

Entidades, medições e relações explícitas.
Exporta JSON, GraphML ou CSV ZIP — a vista
visível e o grafo completo do paciente são
sempre diferenciados.

Entities

case_id	article_id	age	gender	start	end	surface_text	term_norm	cui	tui	entity_type	n_tokens	vo
PMC10106591_01	PMC10106591	44	Female	46	55	emergency	emergency	C2745965	T046	Diagnosis	1	M
PMC10106591_01	PMC10106591	44	Female	115	125	chest pain	chest pain	C0008031	T184	Symptom	2	SI
PMC10106591_01	PMC10106591	44	Female	130	145	chest tightness	chest tightness	C0232292	T184	Symptom	2	SI
PMC10106591_01	PMC10106591	44	Female	212	222	chest pain	chest pain	C0008031	T184	Symptom	2	SI
PMC10106591_01	PMC10106591	44	Female	293	310	retrosternal pain	retrosternal pain	C0151826	T184	Symptom	2	SI
PMC10106591_01	PMC10106591	44	Female	374	380	throat	throat	C0729889	T023	BodyPart	1	SI

Measurements

case_id	article_id	start	end	surface_text	is_range	value	range_low	range_high	unit	unit_norm	unit_category	linked
PMC10106591_01	PMC10106591	236	243	2 weeks	☐	2			weeks	weeks	time	
PMC10106591_01	PMC10106591	624	631	7 years	☐	7			years	years	time	
PMC10106591_01	PMC10106591	686	692	150 mg	☐	150			mg	mg	mass	
PMC10106591_01	PMC10106591	909	916	51 mmHg	☐	51			mmHg	mmhg	pressure	

Relations


source	relation	target	count	link_method
concept:C0003364	ASSOCIATED_WITH_MEASUREMENT	measurement:PMC10106591_01:686:692	None	same_sentence
concept:C0008031	ASSOCIATED_WITH_MEASUREMENT	measurement:PMC10106591_01:236:243	None	same_sentence
concept:C0011900	ASSOCIATED_WITH_MEASUREMENT	measurement:PMC10106591_01:2668:2672	None	same_sentence
concept:C0012373	ASSOCIATED_WITH_MEASUREMENT	measurement:PMC10106591_01:3884:3889	None	same_sentence
concept:C0012373	ASSOCIATED_WITH_MEASUREMENT	measurement:PMC10106591_01:3944:3950	None	same_sentence
concept:C0020538	ASSOCIATED_WITH_MEASUREMENT	measurement:PMC10106591_01:624:631	None	same_sentence

TESTADO EM NÍVEL DE UNIDADE, INTEGRAÇÃO E NAVEGADOR

```
python3 -m unittest discover -s  
tests -v
```

- As 6 relações clínicas tipadas, idade neonatal corrigida, demografia ausente.
- Identidade e offsets de pacientes fundidos; anotações desatualizadas.
- Filtros e exportações; integração de grafo para os 50 pacientes, em ambos os modos.






LIMITES E ENCERRAMENTO

/12

O QUE O GRAFO NÃO AFIRMA

Limites conhecidos


- Uma menção no texto não confirma diagnóstico, tratamento administrado nem causalidade.
- Os vínculos `window_fallback` (79) têm confiança menor que `same_sentence`.



Próximos passos

- Registrar nome, versão e DOI exatos do dataset upstream (pendente em `data/README.md`).
- Explorar modelagem de negação / estado de asserção sobre as menções existentes.





Natural Language Processing

OBRIGADO