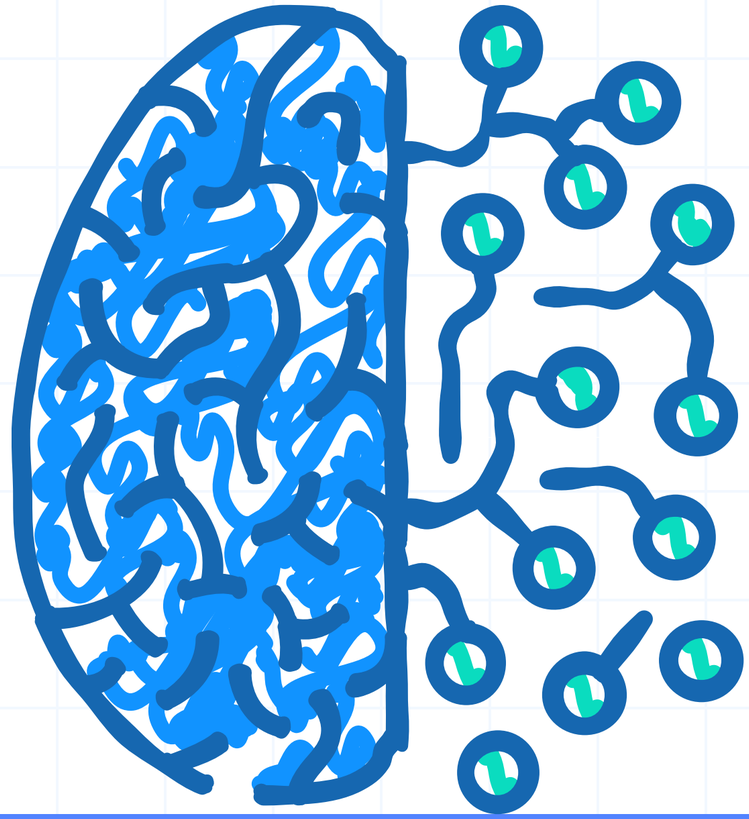
Relações clínicas com n-gramas



Extração de relações com n-gramas, PMI e regressão logística no MultiCaRe, comparada com as regras do Projeto 1

Presented by

Andrés Rodas · Jared Orihuela · Emanuel Ricasca · Diego Monzón · Fernando Foschiera

github.com/JaocHatter/ Projeto-de-Natural-Language-Processing---Knowledge-Graph





Índice

01. Metodologia

02 N-gramas e PMI

03 Atributos e implementação

04 Resultados e supervisão fraca

05 Discussão

06 Grafo

07 Conclusão

Metodologia

Mesmos pares candidatos do Projeto 1; só muda quem decide a relação



413
pares julgados à mão (gold), em 10 casos

1 caso fora
modelo, PMI e modelo de linguagem refeitos sem o caso de teste

10.000
sorteios de bootstrap pareado por caso (IC 95%)

Sem LLMs, embeddings ou Transformers — só biblioteca padrão do Python

O PMI destaca termos clínicos compostos

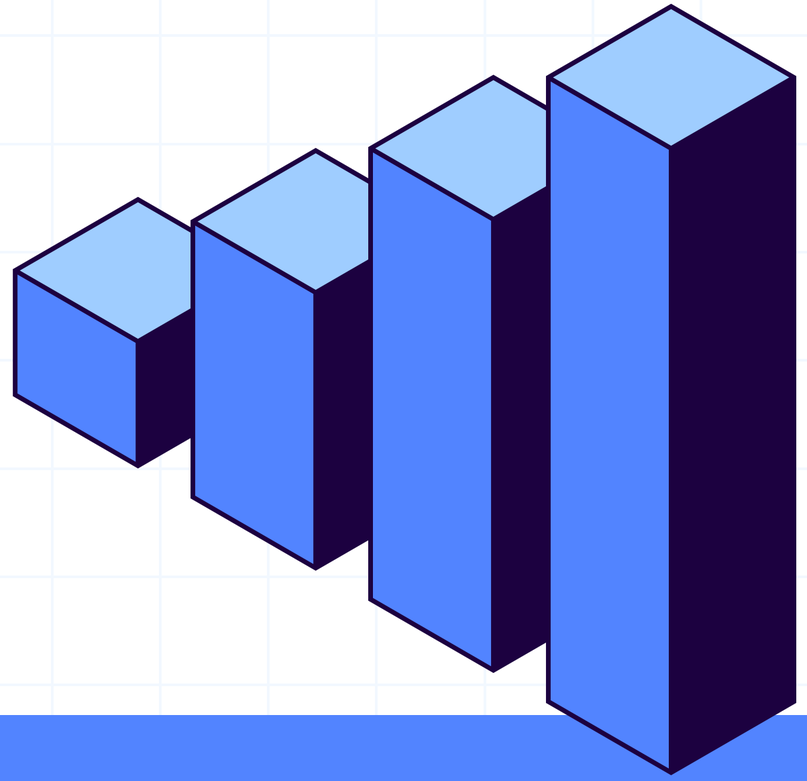
Sem nenhuma lista prévia — a associação vem só do corpus

16.961
bigramas distintos no corpus

81,7%
aparecem uma única vez:
contagem ingênua engana

Bigrama (topo do PMI)	vezes	PMI
magnetic resonance	6	12,05
erythrocyte sedimentation	5	11,79
one-lung ventilation	5	11,31
pleural effusion	7	11,10
human herpesvirus	5	11,05
sinus rhythm	7	10,95

PMI zero abaixo de 5 ocorrências; LLR (Dunning, 1993) ao lado, para dados esparsos.



Gatilhos

Frases mais frequentes entre duas entidades, comparadas com o léxico do P1

53 de 140

gatilhos escritos à mão no P1 aparecem 3+ vezes entre entidades: os dados confirmam parte do léxico

18 de 30

bigramas mais frequentes não contêm nenhum gatilho do P1

No léxico de gatilhos do P1

was performed · due to · showed a · patient underwent · consistent with · presented to · revealed a · physical examination · presented with

Fora do léxico — frequentes mas novas

patient was · to the · with a · from the · did not · he was · based on · with the

Atributos

Três formas de levar os n-gramas ao classificador

1

PMI e LLR

Associação dos bigramas do trecho entre as entidades, comprimida em 3 atributos: PMI máximo, PMI médio e LLR máximo.

2

Modelo de linguagem empilhado

Dois bigramas com add-k: um treinado em pares com relação, outro sem. A diferença vira o lm_score, calculado fora de amostra.

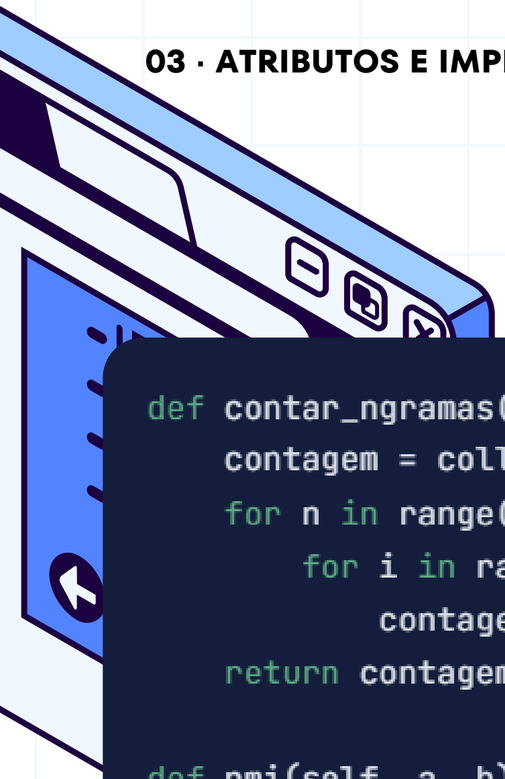
3

Frases diretas

Cada frase de 1 a 3 palavras vista em 2+ pares de treino vira um atributo binário (“treated with” ligado ou não).

Métrica	PMI / LLR	Modelo de linguagem	Frases diretas
F1	0,745	**0,762**	0,720
Precisão	0,674	0,687	**0,712**
Cobertura	0,833	**0,855**	0,729
Tipo certo	0,908	0,889	**0,919**
Acertadas / falsas / perdidas	184 / 89 / 37	189 / 86 / 32	161 / 65 / 60

Junto com tipos das entidades, distância e pontuação → regressão logística um-contra-todos, escrita à mão (SGD + L2), verificada com scikit-learn.



```
def contar_ngramas(tokens, n_max=3):
    contagem = collections.Counter()
    for n in range(1, n_max + 1):
        for i in range(len(tokens) - n + 1):
            contagem[tuple(tokens[i:i + n])] += 1
    return contagem

def pmi(self, a, b):
    c = self.bigramas.get((a, b), 0)
    if c < self.contagem_minima:
        return 0.0
    return math.log2((c / self.total) /
        ((self.unigramas[a] / self.total_palavras) *
         (self.unigramas[b] / self.total_palavras)))
```

Implementação



N-gramas de 1 a 3

Cada janela de n palavras vira uma chave do contador.

PMI

log2 de P(a,b) sobre P(a)·P(b): quanto o par se atrai além do acaso.

Corte de contagem

Evita que um par visto uma única vez ganhe o PMI máximo.

Resultados

Modelo aprendido (P2) contra as regras do Projeto 1, no gold

0,63 -> 0,75
P1 → P2 completo

F1 de detecção

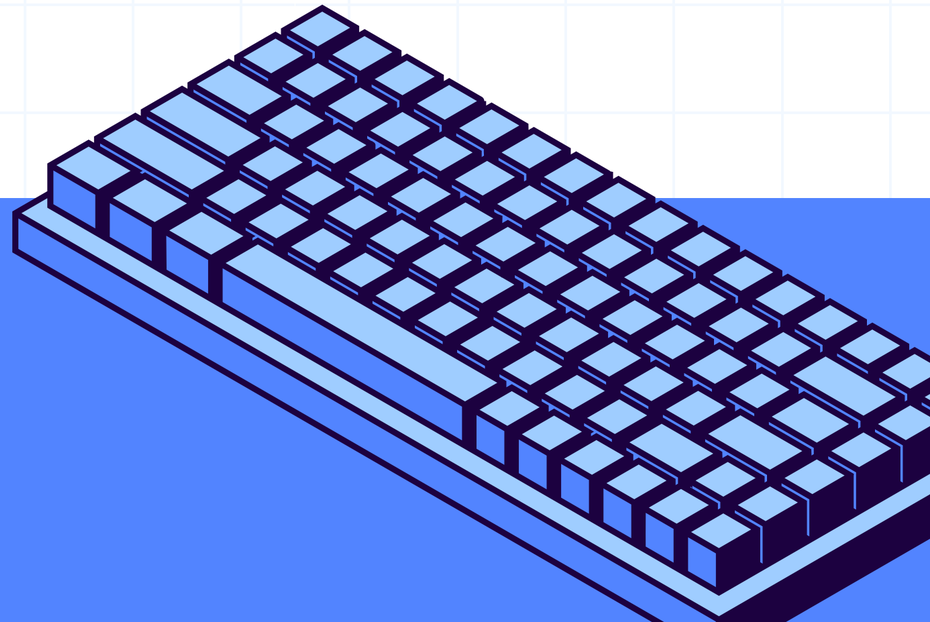
0,77 -> 0,91
entre as relações detectadas

Tipo de relação certo

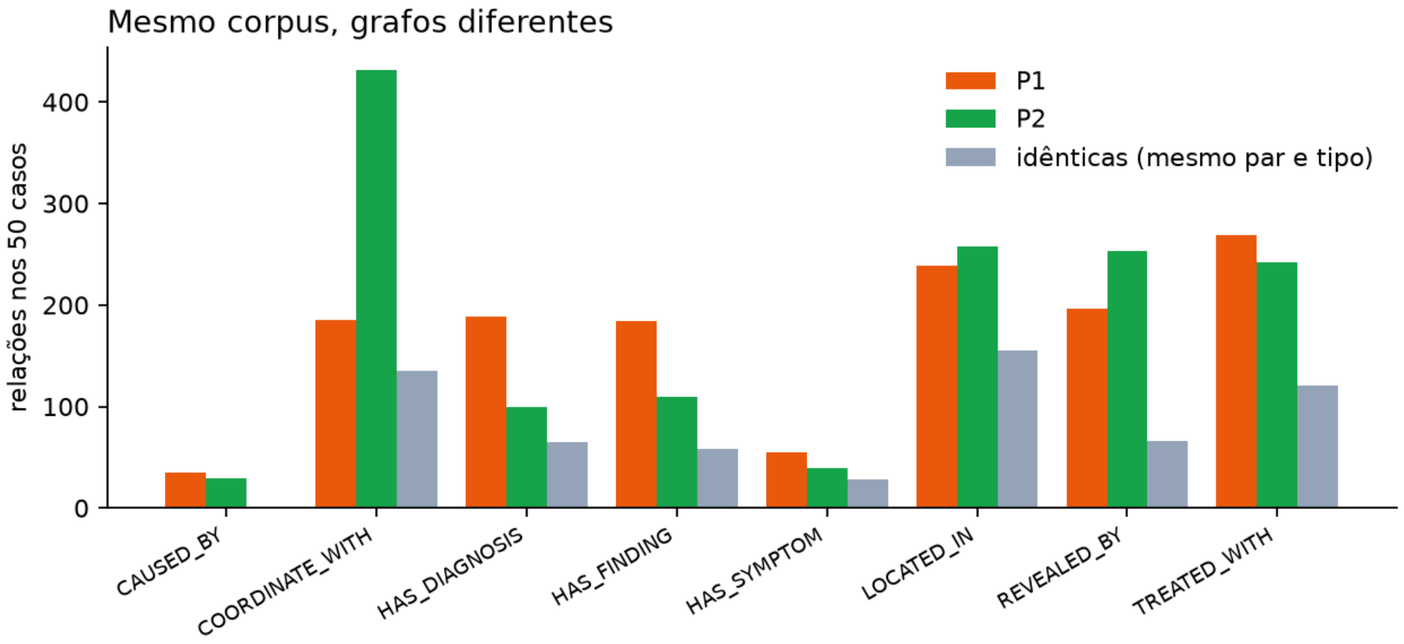
9 de 10
validação deixando um caso fora

Casos em que vence

Diferença de F1 +0,126, IC 95% [+0,084; +0,180]: todo o intervalo acima de zero (bootstrap pareado por caso).



Grafo



0,29

Só 628 de ~1.400 relações coincidem

185 → 432

COORDINATE_WITH: o P2 recupera listas de achados

116 vs 48

pares do gold em que só o P2 acerta, contra só o P1

Mesmo corpus, grafos bem diferentes

Conclusão

Principais resultados e próximos passos



- F1 0,63 → 0,75 e tipo certo 0,77 → 0,91, com intervalo de confiança acima de zero.
- Os n-gramas descobrem termos compostos e gatilhos, e reconstroem as regras sem escrevê-las.
- O ganho vem da estrutura e do classificador; mais frases pedem mais julgamentos humanos.